

AI 智能客服项目

对齐 RAGAS 工业级评测 + 业务四象限指标

AI 产品运营求职作品集

作者：方逸之

日期：2026-06-01

一、项目定位

本项目是面向 AI 产品运营（大厂）求职的作品集，目标是展示一套端到端的 AI 客服系统设计与方法论体系，对齐业界（2025-2026）最前沿的标准。

核心定位：从 0 到 1 搭建一套可对标业界事实标准（RAGAS + 业务四象限）的银行 AI 客服系统，覆盖意图识别、RAG 检索、Agent 编排、评测体系、业务转化漏斗全链路。

1.1 业界对齐表

维度	业界事实标准	本项目实现
评测框架	RAGAS (GitHub 4k+ stars)	4 大核心指标 + 3 项业务扩展

维度	业界事实标准	本项目实现
业务指标	客服中心四象限	7 大指标 + 分层 + 钱效
问题分层	L1/L2/L3 复杂度分层	招行实战分层映射
Badcase 管理	P0/P1/P2 自动定级	24h / 3d / 1w 响应
钱效模型	Uplift Model	ROI + 净节省 + 单次成本对比

二、评测体系：RAGAS 4 大核心指标

RAGAS (Retrieval-Augmented Generation Assessment) 是 RAG 系统的工业界事实标准评测框架。本项目核心评测模块 (src/eval/eval_runner_v6.py) 完整对齐 RAGAS 4 大指标。

2.1 指标定义

指标	公式	业务含义	目标阈值
Faithfulness (忠实度)	可被上下文支持的 claim / 总 claim	防幻觉, 金融硬指标	≥ 0.90
Answer Relevancy	逆向问题 + 余弦相似度均值	防答非所问、冗余信息	≥ 0.85
Context Precision	检索相关片段 / 总片段	检索精准度	≥ 0.80
Context Recall	ground_truth 可被 contexts 覆盖	知识库覆盖度	≥ 0.85

2.2 为什么选 RAGAS

- GitHub 4k+ stars, 工业界事实标准
- 论文: ArXiv:2309.15217
- 阿里、腾讯、字节等大厂广泛引用
- 无参考 (reference-free) 评测, 适合真实业务场景

2.3 业务侧扩展 3 项

指标	说明	目标阈值
Intent Accuracy	核心+次要意图完全匹配	≥ 0.85
Tool Call Accuracy	工具名称+参数全部正确	≥ 0.90
Compliance Safety	未触发诈骗/洗钱/敏感信息泄露	≥ 0.98

三、业务指标体系：四象限联动

业界方法论：单看一个指标会被骗，必须联动看。本项目实现了客服中心业界标准的 7 大业务指标 + L1/L2/L3 分层 + 自动四象限诊断。

3.1 7 大指标 + 分层目标

分类	指标	L1 简单	L2 中等	L3 复杂
效率	P95 响应时长	1.0s	2.5s	5.0s
质量	FCR（首次解决率）	90%	75%	50%
质量	转人工率	5%	15%	50%
体验	CSAT	4.5	4.2	4.0
体验	NPS	50	35	20
成本	单次成本（元）	0.5	1.0	3.0
成本	Uplift ROI	800%	500%	200%

3.2 四象限联动诊断

模式	诊断	根因	行动
A	回复快 + 转人工高 = 没用	知识库不够	扩 FAQ
B	FCR 高 + CSAT 低 = 没共情	话术生硬	加情感识别
C	转人工低 + CSAT 低 = 硬撑（危险）	转人工阈值过高	降阈值
D	响应慢 + FCR 高 = 靠谱	检索慢	加流式输出

四、0→1 搭建方法论

如果你要从零开始搭建一个 AI 智能客服项目，按以下 5 个步骤顺序执行。

Step 1: 业务场景拆解

- L1 (60%) : FAQ/账单查询, 单轮可答, AI 应 90%+ 解决
- L2 (30%) : 需查数据/调工具, AI 应 70%+ 解决
- L3 (10%) : 投诉/纠纷/诈骗/合规, AI 必须识别并转人工

Step 2: 评测先行

- 黄金集 50 条 (核心场景) + 扩展集 200 条 (长尾) + 对抗集 30 条 (边界)
- 标注标准: 准确率/完整性/格式
- 对齐业界: 选 RAGAS (不要自造评分标准)

Step 3: 业务指标绑定

- 7 大指标: CSAT/FCR/转人工率/NPS/响应时长/单次成本/ROI
- 分层评估: L1/L2/L3 各自目标
- 钱效模型: Uplift 计算净节省

Step 4: Badcase 闭环

- 每周 30 条 (10 转人工 + 10 差评 + 10 假解决)
- 分类: 合规风险/金钱损失/知识错误/建议不匹配/边界
- 定级: P0 24h / P1 3d / P2 1w
- WBR 周报驱动迭代

Step 5: A/B 测试

- 改一句话术/加一条知识库 → 10% 流量跑新版
- 关键指标: FCR + CSAT + 转人工率
- 至少跑一周, 给统计显著性

五、技术架构

整体架构遵循业界标准的前后端分离 + 中台能力 + 评测/业务层的分层设计。

5.1 核心模块

模块	技术	关键能力
意图识别	规则 17级 + 模型 + LLM	31 种意图, 83.5% 准确率
RAG 知识库	Chroma + BM25	40 条知识, 混合检索
Agent 编排	LangChain	对话记忆 + 工具调用
评测 v6	对齐 RAGAS	4 项核心 + 3 项业务
业务指标	自研四象限	7 大指标 + 分层 + 钱效
前端	Streamlit	快速演示

5.2 技术栈

层级	技术
后端	Python 3.10 + FastAPI
Agent	LangChain
LLM	DeepSeek API
RAG	Chroma + BM25 混合检索
评测	RAGAS 对齐 + 自研业务指标
前端	Streamlit
CI/CD	GitHub Actions

六、AI 产品运营能力映射

把项目中的具体工作映射到 AI 产品运营岗位的核心职责。

能力项	在项目中的体现	业界方法论
业务场景识别	银行 95555 客服场景	L1/L2/L3 分层（招行实战）
评测体系搭建	RAGAS 4 项 + 业务 3 项	论文：RAGAS ArXiv:2309.15217
RAG 调优	Chroma + BM25 混合	RAGAS 上下文精度/召回
Agent 工程	LangChain + 工具调用	function call 评测
业务转化分析	四象限联动诊断	客服中心白皮书
钱效意识	Uplift Model ROI	因果推断
Badcase 管理	P0/P1/P2 自动定级	大厂周会机制
数据驱动	P50/P95 响应时长	SLA 监控

6.1 面试 STAR 法则

情境 (S)

银行业进入 AI Agent 时代，需要评测 AI 客服的真实业务价值，传统的「准确率 80%」单一指标无法说服业务方投入。

任务 (T)

搭建可对标业界标准（RAGAS）的 AI 客服评测 + 业务转化漏斗分析体系，让 AI 团队和业务方能用同一套指标对话。

行动 (A)

- 引入 RAGAS 4 大核心指标 (faithfulness/answer_relevancy/context_precision/context_recall)
- 设计业务四象限（CSAT/FCR/转人工率/响应时长）分层评估
- 实现 L1/L2/L3 复杂度分层（招行实战）
- 开发 Badcase 周会分析器（P0/P1/P2 自动定级）
- 引入 Uplift Model 计算 ROI 和净节省

结果 (R)

- 评测体系对齐业界事实标准 RAGAS，可对标大厂
- 业务指标体系覆盖 7 大维度 + 3 层分层
- 四象限自动诊断，无需人工肉眼看
- 钱效模型可直接给业务方汇报（ROI、净节省、单次成本）

七、GitHub 与参考

7.1 项目仓库

<https://github.com/FrankFang99/cmb-smart-customer-service>

7.2 关键迭代

Commit	说明
5f069be	意图识别准确率 82.3% → 83.5%
e093519	评测 v6.0 - 对齐 RAGAS
80268e0	业务指标 v1.0 - 四象限
b added6f6	README v2.0 - 新增 0→1 方法论

7.3 业界参考

- RAGAS GitHub: <https://github.com/explodinggradients/ragas> (4k+ stars)
- RAGAS Paper: ArXiv:2309.15217
- DeepEval: <https://github.com/confident-ai/deepeval> (CI/CD 集成)
- RAGChecker: 亚马逊细粒度诊断框架