

AI 产品运营面试题库

小林笔记精华 + 100 道高频题 + 银行业 10 道专项

公众号 @小林面试题笔记 + [CSDN/牛客网](#) + 字节 26 届面经

方逸之 | 2026-06-04 | v2.2

一、小林面试笔记·5 大核心题（带链接）

1.1 Q1: RAG 怎么优化？（高频核心）

来源：公众号 @小林面试题笔记 (xiaolinnote.com)

一句话总结

从"检索不准、召回不全、上下文乱"三个方向下手。

核心优化点

1. 数据预处理优化

- 文档清洗：去噪、去重、去乱码
- 分块优化：固定分块 → 语义分块 / 按标题分块 / 递归分块
- 增加元数据：文件名、章节、页码、时间，用于过滤

2. 检索层优化（最重要）

- 向量模型升级：通用 embedding → 领域专用 embedding
- 多路召回：向量检索 + 关键词检索 (BM25) + 时间过滤
- 重排序 (Rerank)：用小模型精排，大幅提升准确率
- 检索阈值：设置相似度分数过滤无关内容

3. Prompt 优化

- 强制要求"只使用参考资料回答"
- 不知道就说不知道，禁止编造
- 给参考资料加编号，要求引用来源

4. 架构优化

- 多轮检索：复杂问题拆步骤，分步查资料
- 上下文压缩：把召回的长文本压缩成关键信息
- 路由 RAG：简单问题直接答，复杂问题才检索

5. 评估优化

- 用指标：召回率、精确率、命中率、幻觉率
- 用 LLM 自动评估回答质量

面试标准回答

RAG

优化围绕"数据、检索、提示词、架构、评估"五方面。先做文档清洗与语义分块，再用多路召回+重排序提升检索精度，通过 Prompt 约束模型只依赖资料，复杂问题用多轮检索与上下文压缩，最后通过自动化评估持续迭代。

1.2 Q2: Agent 卡死怎么办?

- Agent 卡死 = 无限循环 / 工具调用失败 / 思考停滞 / 格式解析错误

解决方案

- 设置最大步数（最有效）：限制最大思考/工具调用次数（如 5-10 步），超限直接退出
- 工具调用异常捕获：超时、报错、无返回 → 捕获后给 Agent 明确提示
- 格式解析容错：卡死 90% 是因为模型输出格式不对（少括号、JSON 错误）→ 解析容错 + 正则修复 + 格式强校验
- 状态监控 + 重启机制：记录每一步状态，长时间无响应自动终止
- Prompt 防循环：明确禁止重复调用相同工具 + 让 Agent 记住上一步做了什么
- 回滚机制：卡死时返回上一步结果，或直接给出总结答案

面试标准回答

Agent 卡死主要来自“无限循环、工具异常、格式解析失败”。解决方案：设置最大执行步数、工具调用异常捕获、强化输出格式校验与容错、增加循环检测、状态监控超时退出，确保流程可终止。

1.3 Q3: 如何降低幻觉?

- 幻觉 = 模型编造信息、无中生有、瞎编结论

最有效方案

- RAG 强制检索：所有事实性问题必须查资料，不检索不回答
- 强约束 Prompt：
 - “不知道就说不知道，严禁编造”
 - “必须引用参考资料内容”
 - “禁止扩展未提及信息”
- 高质量检索：召回越准，幻觉越低 → Rerank + 多路召回
- 事实校验（Fact Checking）：用 LLM 二次校验
- 少样本/思维链引导：给模型看“正确回答”和“拒绝编造”的例子
- 模型选择：用更稳定、更听话的模型（GPT-4o、Claude 系列幻觉更低）

面试标准回答

降低幻觉核心是让模型“有依据说话”——通过 RAG 提供真实资料，用 Prompt 强制禁止编造，通过高质量检索保证依据可靠，再增加事实校验环节，从源头杜绝无依据生成。

1.4 Q4: 如何做工具调度?

- 工具调度 = Agent 该在什么时候、调用哪个工具、怎么选最优路径

标准架构

1. 工具注册与描述

每个工具写清晰：功能、入参、使用场景

2. 工具路由 (Tool Router)

- 方法 1: LLM 自主判断 (最常用)
- 方法 2: 分类器/规则路由 (速度快、稳定)

3. 工具调用决策链

- 判断是否需要工具
- 选择最合适工具
- 生成正确参数
- 执行并解析结果
- 判断是否需要继续调用

4. 多工具调度策略

- 并行调用：同时查多个工具提升速度
- 串行调用：步骤依赖，一步一步来
- 条件调度：根据上一步结果决定下一步

面试标准回答

工具调度包括"工具描述、路由选择、参数生成、执行解析、流程控制"。通过清晰的工具描述让模型理解能力，用路由策略选择合适工具，支持串行/并行/条件执行，并增加异常重试与降级机制，保证稳定可用。

1.5 Q5: 长上下文怎么处理?

- 长上下文 = 文档太长、对话太长、模型装不下、注意力漂移

工业界方案

- 文本分块 (最基础)：大文件切小块，只召回最相关的
- 上下文压缩：摘要压缩 / 抽取式压缩
- 动态窗口 / 滑动窗口：只保留最近 N 轮对话 + 关键历史
- 向量记忆 (长期记忆)：历史对话存向量库，需要时检索
- 总结记忆：旧历史自动生成摘要，节省 token
- 注意力优化：关键信息前置 + 用 Claude/Qwen Long 等长上下文模型
- 分层存储：短期记忆 (原始对话) + 长期记忆 (摘要/向量)

面试标准回答

长上下文处理采用"分块检索、动态压缩、分层记忆"策略——长文档切分后只召回相关片段，对话历史用摘要+向量库管理，结合动态窗口控制长度，在有限上下文内保留最有价值信息。

二、100 道 AI 产品经理高频面试题

2.1 基础认知（25 道精选）

#	题目
1	AI 产品经理 vs 普通产品经理
2	大模型/NLP/CV/AIGC/RAG/Agent 一句话讲清楚
3	主流大模型有哪些？各自特点？
4	AI 产品的核心难点
5	AI 产品分类（应用层/技术层/基础层）
6	AI 产品三种角色
7	机器学习 vs 深度学习
8	自然语言处理是什么
9	ML 模型性能评估指标
10	过拟合 vs 欠拟合
11	Transformer 核心
12	预训练 vs 微调
13	向量数据库 / RAG
14	Prompt 工程要素
15	AI 幻觉
16	训练数据采集
17	数据漂移（Data Drift）
18	冷启动
19	A/B 测试
20	多模态
21	AI 商业模式
22	AI 伦理
23	AI 行业潜力
24	你最近关注的 AI 产品
25	银行/金融 AI 产品的特殊要求

2.2 技术理解（20 道精选）

#	题目	要点
1	RAG 解决什么问题	幻觉/实时性/数据安全
2	Agent 工作流程	LLM 决策 + 工具调用 + 反思
3	大模型幻觉怎么解决	RAG + 校验器 + 人工复核
4	微调 vs Prompt	微调领域适配 / Prompt 快速迭代
5	AI 效果评估指标	业务/模型/体验 三层
6	检索质量评估	Recall / Precision / MRR
7	Embedding 选型	BGE / M3E / text-embedding-3
8	混合检索	BM25 + 向量 RRF 融合
9	HyDE	生成假设答案再检索
10	ReRank	cross-encoder 精排
11	Agent 框架选型	LangGraph/AutoGen/Coze
12	MCP 协议	Anthropic 工具标准
13	Function Calling	JSON Schema + Pydantic
14	Multi-Agent 协同	Planner/Executor/Critic
15	指标体系分层	业务/模型/体验
16	Badcase 回流	Trace + 标注 + 回归集
17	CoT 思维链	强制思考过程可见
18	可解释性	银保监硬性要求
19	端侧 AI	离线/低延迟/隐私
20	LoRA 微调	低秩适配，省算力

2.3 产品设计（15 道精选）

#	题目	要点
1	怎么设计 AI 客服产品	需求调研 + 意图体系 + RAG + 评测
2	AI 对话产品交互设计	历史/打断/澄清/重试/撤回
3	需求优先级	影响×努力矩阵
4	模型不稳定/慢/贵怎么优化	小模型+缓存+异步+分层
5	AI 知识库核心流程	文档→切片→向量化→检索→生成
6	用户说 AI 不好用怎么定位	日志+Trace+badcase 分析
7	AI 产品 MVP 设计	最小可用 + 关键指标
8	上线后关注指标	FCR/CSAT/转人工率/响应时长
9	AI 产品竞品分析	传统+AI 维度对比
10	付费功能差异点	基础免费 + 高级订阅
11	用户教育	引导文案 + 教程 + 案例
12	用户分层订阅	免费/标准/企业版
13	避免信息茧房	多样性 + 主动探索
14	冷启动增长	种子用户 + KOL + 运营

#	题目	要点
15	AI PRD vs 传统 PRD	加 Prompt/评测/兜底 3 部分

2.4 项目与复盘（10 道精选）

#	题目	要点
1	最成功的 AI 项目	STAR：情境/任务/行动/结果
2	项目最大风险	提前识别 + 预案
3	和算法/研发协作	需求评审 + 排期 + 联调
4	AI 产品价值衡量	效率/成本/收入/体验
5	模型效果不达预期	badcase 分析 + 数据补充
6	需求到上线全流程	亚慧方法论 9 步
7	算法反馈成本高	降级方案 + 备选模型
8	上线后效果下降	数据漂移 + 监控告警
9	版本迭代计划	灰度 + A/B + 指标
10	数据不足补充	冷启动 + 用户反馈 + 合成

2.5 业务/行业/商业化/压力（20 道精选）

#	题目	要点
1	未来 1-2 年 AI 机会	Agent + 多模态 + 行业落地
2	To C vs To B AI 产品	用户体验 vs 业务流程
3	银行 AI 特殊要求	合规/数据安全/可解释
4	AI 客服最佳实践	意图识别 + RAG + 转人工
5	AI 取代人工	替代重复劳动 + 创造新岗位
6	AI 商业模式	API/订阅/私有化/混合
7	AI 产品护城河	数据 + 场景 + 工程
8	海外市场	本地化 + 跨语言 + 合规
9	大厂 AI 缩编	聚焦高价值场景
10	值得深耕方向	Agent + 行业 + 多模态
11	核心 3 个能力	场景拆解+Prompt 设计+数据驱动
12	没算法背景怎么做	业务理解 + 工具使用
13	研发说实现不了	降级方案 + 备选路径
14	1-3 年职业规划	AI PM → 高级 → 总监
15	最失败的项目	复盘 + 学到什么
16	跨部门冲突	对齐目标 + 找决策人
17	差异化优势	金融背景 + 数据 + AI
18	加班	效率 + 主动沟通
19	快速学新技术	动手 + 文档 + 社群
20	职业天花板	AI PM 横向 + 纵向

三、银行业 AI 客服专项（10 道）

招行 95555 真实场景 · 必问

#	题目	答题要点
1	银行业 AI 客服有什么特殊要求	L0 红线（反洗钱/反诈骗）必须 100% 转人工
2	客户输入银行卡号/密码怎么处理	敏感信息检测 → 立即拦截 + 提示
3	贷款类问题怎么回答	必须说"年化利率"等监管话术
4	客户投诉怎么转人工	置信度 < 0.6 立即转
5	反洗钱关键词触发后怎么上报	立即转人工 + 同步合规系统
6	钱效怎么算	(节省人力 - AI 投入 - 合规成本)/投入
7	等保三级是什么	银行业硬性合规要求（30-50 万）
8	银保监要求多久汇报一次	季度汇报 + 年度审计
9	数据本地化怎么做	不能上公有云，必须私有部署
10	人工复核比例是多少	L3 复杂场景 100% 人工复核

银行业 5 项专属指标（高于通用版）

指标	通用版	银行业版
敏感信息检测	3 种（身份证/手机/密码）	7 种（+ 卡号/CVV/验证码/大额）
合规话术	可选	必填（4 套：贷款/反诈/AML/隐私）
越权访问	无	代查他人账户 100% 转人工
L0 红线	无	L0 场景 100% 转人工 + 100% 上报
钱效模型	ROI	ROI - 合规成本

四、面试 STAR 法则（银行业 AI 客服项目）

情境 (S)

银行业进入 AI Agent 时代，传统"准确率 80%"单一指标无法说服业务方投入。L0 红线（反洗钱/反诈骗/越权）触发即事故，监管硬性要求 100% 转人工。

任务 (T)

搭建可对标业界标准（RAGAS）的 AI 客服评测 + 业务转化漏斗分析体系；让 AI 团队和业务方能用同一套指标对话。

行动 (A)

- 引入 RAGAS 4 项核心指标 (faithfulness/answer_relevancy/context_precision/context_recall)
- 设计 Adapter 模式 (BaseRAGASAdapter + BankingMixin)，保留通用性 + 银行业专属
- 银行业 5 项业务扩展 (敏感泄露/监管话术/越权/L0 红线/意图准确率)
- 业务四象限 (CSAT/FCR/转人工率/响应时长) + 钱效模型扣合规成本
- L0-L3 四级分层 (红线 < 1% / 简单 60% / 中等 30% / 复杂 10%)
- 4 段上线法 (内测→白名单→灰度→全量)

结果 (R)

- 评测体系对齐业界事实标准 RAGAS
- 业务指标体系覆盖 7 大维度 + 3 层分层 + L0 红线
- 意图识别准确率 83.5% (600 条真实评测)
- 钱效模型可直接给业务方汇报 (净节省 / ROI / 单次成本)
- GitHub: <https://github.com/FrankFang99/cmb-smart-customer-service>

五、引用来源（每题带链接）

来源	链接	内容
小林面试笔记 · Agent 高频题	xiaolinnote.com / 公众号 @小林面试题笔记	RAG/Agent/工具调度/长上下文 5 题
字节跳动 AI Agent 二面	blog.csdn.net/qq_37427142/article/details/141759818	RAG 3 步讲全流程
CSDN 100 道 AI PM 题	blog.csdn.net/MINANZHIKU/article/details/125616784	6 维度 100 题
牛客网 AI 运营题单	nowcoder.com	业务/逻辑/压力题
字节 26 届 AI PM 面经	finance.sina.com.cn	飞书 AI 智能伙伴设计
亚慧 AI 产品经理	B站/抖音同名	35 节课方法论 + 7 步法
RAGAS	github.com/explodinggradients/ragas	工业级评测框架
微众银行《联邦大模型白皮书》	-	银行业 AI 实践
央行《商业银行 AI 应用合规指引》	2025 年 1 月	银行业监管要求

六、面试备考核心建议

6.1 小林笔记的 5 道核心题必背

- RAG 优化：从数据/检索/Prompt/架构/评估五方面讲
- Agent 卡死：最大步数 + 异常捕获 + 格式容错 + 防循环
- 降低幻觉：RAG 依据 + 禁止编造 + 事实校验
- 工具调度：工具描述 + 路由选择 + 串行/并行 + 重试降级
- 长上下文：分块检索 + 动态压缩 + 分层记忆

6.2 项目可展开为 10 道面试题

- AI 客服项目介绍 / RAG 优化 / Agent 卡死 / 降低幻觉
- 评测体系 / 银行业特殊要求 / 钱效 / Adapter 模式
- 意图识别 17 级规则 / L0 红线风控

6.3 银行业必问 10 道

- L0 红线 / 敏感信息 / 监管话术 / 投诉转人工 / 反洗钱上报
- 钱效 / 等保三级 / 银保监汇报 / 数据本地化 / 人工复核

6.4 答面试题的"万能公式"

STAR（情境/任务/行动/结果）+ 数据量化 + 业界对齐 + 项目可落地

例：意图识别准确率 83.5%（600 条真实评测）—— 数字 + 范围 + 量化